一页结论:同一批财报,什么问题该建库、什么问题该微调

仓库:Chen-jia-xin-ai/baijiu-fin-rag · **10 题逐题(实际召回块 / 模型答案 / 判分 / 错误位置)+ 逐家取证**见 `docs/核验报告.pdf`
官方来源:48 份年报/半年报的巨潮官方公告详情页与 PDF 直链见 `docs/来源清单.csv`(12 家 × 4 期);下面每题引用的页码都可用它回原文逐页核对。

语料:白酒 12 家上市公司 × 4 期(2023/2024/2025 年报 + 2026 半年报)= 48 份 PDF、8,288 页、12,435 张表、96,196 条结构化行;建成 **页级块 34,097 + 行级单元 66,839** 两级索引,每级各带向量(bge-small-zh)与 BM25 两路。10 道**手工撰写**的题(含 3 道跨公司全景题:Q5/Q6/Q7),逐题记录召回块、判分与失败码。

带日期的事实进库;算术与全库聚合进表格工具;口径、文风、领域词映射进权重 —— 是三桶,不是两桶。

桶	装什么	本作业的题	为什么不是另外两个
可检索的库 向量 + BM25 + 页码/报告期元数据	带日期、带版本的事实:某年某公司的某科目余额、某次分红方案、某条会计政策	Q1–Q4、Q8、Q9 **(8/10)**	微调会把 FY2023 的数字在 FY2026 的问题上张口就来,**且给不出出处** —— 而「答案带出处」是本题硬要求
表格工具 pandas over `data/tables/tables.jsonl`	算术、排名、全库聚合:12 家里谁最低、同比差多少、三家排序	Q7(12 家销售费用率最低)、Q8、Q6	朴素 RAG 的**结构性盲区**:top-k 给不了全量,顺序也不写在任何一页上;微调同样不行,它没有可枚举的输入
权重 微调 / 领域词典 / 查询改写	口径与文风(稳定的带引用对比表)、**领域词到科目的映射**	Q10(「经销商打款意愿」→「合同负债」)	16MB 文本远不足以把事实装进参数;但对学**格式**和**词→科目映射**刚好合适

Q7、Q8 是**故意设计的翻车题**,Q10 是**实测翻车** —— 翻车不是缺陷,是上表的证据。`scripts/05_eval.py` 里有 pandas 兜底,把同样的问题算得又对又精确,并排放在结果里对照。

数字

检索配置	recall@5	MRR		检索配置	recall@5	MRR
`hybrid`(基线)	6/14	0.434		`row`(仅行级)	9/14	0.483
`hybrid-noroute`	6/14	0.434		`hybrid-row`	8/14	0.533
`vector` / `bm25` 单路	7/14 / 3/14	0.417 / 0.263		**`hybrid-row+filter` ★**	**9/14**	**0.600**

答案判分:**基线 3/10 答对 → 改进后 5/10 答对 + 2 部分对**(Q2、Q8 由错转对;Q6、Q9 由错转部分对)。**同时如实记一条退化:Q5 由「部分对」掉到「错」**(根因见要点 3)。

三条要点

1. **「表格按行列还原」是能不能检索到的问题,不是格式问题。** 管道表把「合同负债」和它的数值隔开几百个 token,分块后标签与数字大概率分属不同块。行线性化(`项目=合同负债 | 期末余额=…`)让标签紧挨数值,这道题才捞得回来。
2. **「报告期」写在文本里,和「报告期」是个字段,是两回事。** 自描述前缀里确有「2025年年度报告」也进了 BM25 词表,但 `2025` / `2023` 都是高 df 数字,几乎没有区分力;向量上 FY2023 里**逐字相同**的风险段落同样像答案。变成**布尔过滤条件**后收益最大(MRR 0.533 → 0.600)—— 这就是「该建库」的字面含义:**不是把事实埋进向量,是给事实结构化字段。**
3. **行级索引解决了「答案在表里但被切碎」,却引入「明细行压过合计行」。** 一张合并资产负债表线性化后两三千字,切完分块,「合同负债」那一行掉进哪块纯属运气;降到行粒度后 Q2、Q8 立刻转对。但 Q5 因此退化:营业收入在语料里有四处,行级索引把「省内/省外/合计」拆成**平级**行,分解表每一行都复读了列名「营业收入」,而合计行只有一行还更长,于是越细的行越像答案,四路 RRF 的共识票把它顶到第 1。**正解是让行保留表的层级(合计是明细的父节点);加权与砍路径都试过,recall@5 反降到 6/10,不采纳。**

错在哪

10 题里 8 题的错都能归到「没召回 / 召回错」;**真正的阅读失败只有两例。**

题	题型	结果	失败码
Q5	跨公司对比	❌	`RETRIEVAL_MISS` —— 明细行压过合计行(见要点 3)
Q6	跨公司对比	⚠️	`READ_ERROR` —— 三家都召回了,「排序」这一步没有哪一块能提供
Q7	跨 12 家排序	🚫 拒答	`AGGREGATION_FAIL` —— 预期翻车,正确出口是表格工具
Q9	跨报告期	⚠️	`PERIOD_CONFUSION` —— 三个年末的数分散在三份年报里
Q10	语义词汇不匹配	❌	`RETRIEVAL_MISS` —— 题面高频词「经销商」把四条路径**全**拽到经销商数量表上,真正回答它的「合同负债」根本没进 top-10

Q1–Q4、Q8 全对(Q4 靠 `scope` 字段区分合并/母公司;Q8 元与亿元换算对了就不翻车)。

微调解决不了这三桶里的任何一桶:它给不出出处(第 1 桶要)、没有可枚举的输入(第 2 桶要)、也不该用来记 16MB 流水账(第 3 桶里只有**格式与映射**那部分值得)。反过来 —— 事实交给库、算术交给 pandas、口径与文风交给权重 —— 每一样都用在了它擅长的地方,这比「全都塞进模型」既便宜,也可验证。